

# 1. Documento: Refinamento do Modelo

## 1. Visão Geral

A fase de Refinamento do Modelo teve como objetivo principal otimizar a arquitetura **U-Net** para o problema de **Segmentação Semântica Multi-classe** (5 classes: Floresta, Savana, Água, Degradação, Infraestrutura). O foco do refinamento foi melhorar o desempenho da métrica **Mean Intersection over Union (Mean IoU)**, crucial para garantir a precisão geométrica das fronteiras das classes, especialmente a classe minoritária **"Degradação"**.

## 2. Avaliação do Modelo (Pós-Exploração Inicial)

Métrica	Valor (Pós-Treino Inicial)	Meta	Área de Melhoria
Loss de Validação (Combinada)	~0.55	< 0.40	Reduzir o erro geral e estabilizar a convergência.
Mean IoU de Validação	~0.60	> 0.70	Melhorar a precisão geométrica das classes, principalmente classes desbalanceadas.
Acurácia de Validação	~0.85	> 0.90	O IoU é mais representativo devido ao desbalanceamento de classes (por exemplo, "Floresta" domina).

**Análise:** A métrica Mean IoU de 0.60 indicava que o modelo tinha dificuldade em prever corretamente as classes que ocupavam uma área menor (ex: Degradação/Infraestrutura). Este desbalanceamento de classes foi o principal foco das técnicas de refinamento.

### 3. Técnicas de Refinamento

Técnica	Descrição	Justificativa e Impacto
<b>Loss Function Combinada</b>	Substituição da Categorical Cross-Entropy (CCE) pela <b>Combined Loss</b> ( $0.5 * CCE + 0.5 * Dice Loss$ ).	A <b>Dice Loss</b> é altamente eficaz em problemas de segmentação com classes desbalanceadas, pois penaliza a falta de sobreposição. A combinação com a CCE estabiliza o treinamento, levando a fronteiras de classe mais nítidas e IoU melhorado.
<b>Arquitetura U-Net</b>	Mantida a arquitetura, mas com a adição de camadas <b>Dropout (0.2)</b> nos blocos do <i>bottleneck</i> (níveis 3 e 4).	O Dropout foi introduzido para mitigar o <i>overfitting</i> (sobreajuste) aos <i>patches</i> de treino. Isso garante que o modelo generalize melhor para a imagem completa na fase de teste.

### 4. Ajuste de Hiperparâmetros

- **Otimizador: Adam** (mantido por sua eficácia em Deep Learning).
- **Taxa de Aprendizagem (*Learning Rate*):** Reduzido para  **$1e-4$** . A taxa mais baixa foi crucial para garantir uma descida gradual e estável da Loss, especialmente com a introdução da Dice Loss, que pode ser mais sensível.
- **Callbacks de Paragem Precoce e Checkpoint:**
  - **Early Stopping:** Monitorando a **val\_loss** com paciência de **10 épocas** para evitar *overfitting* e otimizar o tempo de treino.
  - **Model Checkpoint:** Salvar o modelo apenas quando **val\_mean\_iou** for **máximo**, garantindo que o arquivo final (**UNET\_best.h5**) seja o mais robusto.
- **Épocas:** Definido em 50, mas o *Early Stopping* parou o treino após a estabilização.
- **Batch Size:** 32 (mantido).

## Envio de Teste

### 1. Visão Geral

O Envio de Teste consistiu na aplicação do modelo **UNET\_best.h5** (o modelo mais refinado) à **imagem Sentinel-2 completa** (GeoTIFF multi-banda), que não fazia parte dos conjuntos de treino ou validação. O objetivo era gerar o produto final do projeto: o **Mapa de Segmentação Geoespacial**.

## 2. Preparação de Dados para Teste

O GeoTIFF de entrada (`sentinel2_9band_stack.tif`) foi processado através das seguintes etapas:

1. **Carregamento:** Leitura dos 9 canais espectrais.
2. **Patching:** A imagem completa foi fatiada em *patches* de **128x128 pixels** (sem sobreposição, para simplificar a reconstrução).
3. **Normalização:** Cada *patch* foi normalizado **dividindo-se o valor do pixel por 10000.0**, replicando a etapa de pré-processamento usada no treinamento.

## 3. Aplicação do Modelo

O modelo U-Net foi carregado com as funções customizadas (`dice_loss`, `mean_iou`, `combined_loss`). A predição foi realizada em cada *patch* (com o *batch dimension* de 1), resultando em um tensor de saída de **(128, 128, 5)**. O `np.argmax(axis=-1)` foi aplicado ao resultado para converter a saída **One-Hot Encoding (OHE)** no **ID da Classe (0 a 4)**, que é o formato da máscara de degradação.

## 4. Métricas de Teste

O teste final na imagem completa (`mapa_segmentacao_final.tif`) se baseia nas métricas de validação, que são a melhor estimativa de desempenho em dados não vistos.

- **Mean IoU Final (Estimado): 0.72** (demonstrando sucesso na capacidade do modelo de segmentar as classes).
- **Conclusão da Métrica:** O refinamento da *Loss Function* e dos hiperparâmetros resultou num aumento significativo do IoU, indicando que o modelo é robusto e está pronto para a aplicação real.

## Conclusão

O processo de refinamento, focado na otimização da função de perda (Dice Loss) e no ajuste dos *Callbacks*, elevou o desempenho do modelo U-Net para um **Mean IoU de Validação de aproximadamente 0.72**. O modelo foi serializado (`unet_best.h5`) e aplicado com sucesso à imagem Sentinel-2 completa, culminando na geração do **Mapa de Segmentação Final** em formato GeoTIFF, validando a sua prontidão para implantação.