

Diretriz do Projeto: Envio de Proposta de Ideia

Título do Projeto: Detenção de Mudanças e Degradação de Habitats por Imagens de Satélites para o Ecoturismo Angolano

1. Ideia do Projeto

Problema: A rápida degradação de habitats (desflorestação, erosão, etc.) em áreas de conservação, como o **Parque Nacional da Quiçama**, ameaça a integridade dos ecossistemas e o potencial do Ecoturismo Angolano.

Objetivo Específico: Desenvolver um sistema automatizado de **Segmentação Semântica** usando Deep Learning (U-Net) para monitorizar e classificar o uso e cobertura do solo. O produto final é uma **ferramenta de alerta de detenção precoce** que apoia a gestão sustentável e inteligente dessas regiões.

2. Relevância para os Objetivos de Desenvolvimento Sustentável (ODS)

O projeto contribui diretamente para os seguintes ODS:

- **ODS 15 (Vida na Terra):** Monitoriza ecossistemas vitais, identificando a perda de conservação e degradação de terras (Meta 15.1).
 - **ODS 13 (Ação Climática):** Fornece dados geoespaciais precisos para detetar áreas de desflorestação e degradação de sumidouros de carbono, apoiando a mitigação das alterações climáticas (Meta 13.2).
 - **ODS 17 (Parceria para os Objetivos):** Promove a transferência e o uso de tecnologia limpa e dados globais (Sensoriamento Remoto) em benefício do desenvolvimento local (Metas 17.8 e 17.18).
-

3. Exemplos de Literatura

1. **Ma, L. et al. (2029). Deep Learning in Remote Sensing Applications: A Meta-Analysis and Review.** (ISPRS Journal of Photogrammetry and Remote Sensing).
 - **Relevância:** Artigo central que demonstra o sucesso das Redes Neurais Convolucionais (CNNs) na classificação de uso do solo e detecção de mudanças ambientais em dados de satélite.
2. **Zhu, X. X. et al. (2017). Deep Learning in Remote Sensing: A Comprehensive Review and List of Resources.** (IEEE Geoscience and Remote Sensing Magazine).
 - **Relevância:** Explora metodologias de Aprendizado Profundo aplicadas à monitorização ambiental e conservação de ecossistemas, justificando a escolha desta abordagem pela sua capacidade de extrair padrões complexos.

4. Descreva Seus Dados

- **Fonte:** Dados de satélites digitais **gratuitos e globais**, principalmente **Sentinel-2 (ESA)** e potencialmente Landsat 8/9 (USGS/NASA).
- **Formato:** Imagens **Multiespectrais** (9 bandas) no formato **GeoTIFF**.
- **Pré-processamento:** Correções atmosféricas, recorte geográfico (para a área de estudo) e **normalização das bandas espectrais** (divisão por 10000.0) para preparar os dados para o modelo.
- **Classes de Interesse:** Floresta, Savana, Água, **Degradação/Solo Exposto** e Infraestrutura.

5. Abordagem (Aprendizado Profundo)

Escolha: Aprendizado Profundo (Deep Learning).

Justificativa: A tarefa de **Segmentação Semântica** (classificação pixel a pixel) em imagens complexas e multi-banda requer uma arquitetura que possa aprender hierarquicamente as características espaciais e espectrais. O modelo **U-Net** foi selecionado por ser o padrão ouro na segmentação de imagens geoespaciais e médicas, devido à sua arquitetura de **encoder-decoder** com *skip connections*, que assegura alta precisão na localização dos limites das classes de degradação.