

# Documentação: Revisão de Literatura, Dados e Tecnologia

## 1. Preparando sua Revisão de Literatura

### Introdução

A pesquisa sobre a detecção de mudanças e a degradação de habitats é crucial para a gestão ambiental em áreas de ecoturismo. Uma revisão da literatura existente é necessária para fundamentar o projeto em metodologias robustas, comprovando a eficácia do Sensoriamento Remoto (SR) e do Aprendizado de Máquina (ML) na identificação e monitoramento de padrões de uso do solo.

### Organização, Resumo e Síntese

A pesquisa foca em três temas principais: **Detecção de Mudanças por SR, Algoritmos Tradicionais de ML em SR** e a transição para **Deep Learning (DL)**.

#### 1. Detecção de Mudanças e Uso Multitemporal:

- **Lu, D. et al. (2004) & Canty, M. J. (2019):** Estes trabalhos estabeleceram a base para a análise multitemporal, destacando a importância de índices espectrais (como NDVI/NDWI) e o processamento de imagens geoespaciais (GeoTIFF) para detectar alterações na paisagem. Eles fornecem o contexto para o pré-processamento de dados Sentinel-2.

#### 2. Algoritmos Tradicionais de ML em SR:

- **Belgui, M. & Drăguț, L. (2016):** Reforçaram a aplicabilidade de algoritmos como **Random Forest (RF)** em SR, elogiando sua robustez contra ruídos e o manejo eficiente de variáveis correlacionadas (como as bandas multiespectrais). O RF serve como um **modelo baseline** para comparar o desempenho do modelo Deep Learning.

#### 3. Avanços com Deep Learning em SR:

- **Ma, L. et al. (2029) & Zhu, X. X. et al. (2017):** Estes artigos consolidam a transição do ML tradicional para o **Deep Learning (DL)**, especificamente as Redes Neurais Convolucionais (**CNNs**). O DL é justificado pela sua capacidade superior de extrair padrões hierárquicos complexos e realizar a **Segmentação Semântica** (classificação pixel-a-pixel), uma tarefa inatingível com métodos de classificação tradicionais.

### Conclusão

A literatura existente demonstra uma evolução clara das técnicas de classificação. Enquanto algoritmos como Random Forest são eficazes, a complexidade da segmentação multi-classe em dados de satélite exige o poder do Deep Learning. Nosso projeto contribuirá para o corpo de conhecimento existente ao aplicar a arquitetura **U-Net** para **segmentação multi-classe de**

**degradação** num contexto de conservação angolano, oferecendo uma ferramenta de monitorização de alta precisão.

---

## 2. Preparando sua Pesquisa de Dados

### Introdução

A qualidade e o pré-processamento dos dados de satélite são os pilares para o sucesso do modelo de Segmentação Semântica. A escolha de dados abertos garante a replicabilidade e sustentabilidade do projeto.

### Fontes e Tipo de Dados

- **Fonte Primária:** Satélite **Sentinel-2** da Agência Espacial Europeia (ESA).
- **Fonte Secundária (Potencial):** **Landsat 8/9** (USGS/NASA) para séries temporais mais longas ou complementação de dados.
- **Tipo de Dado:** Imagens **Multiespectrais** (10m de resolução) com 9 bandas (incluindo Bandas Vermelho, Verde, Azul, Infravermelho Próximo (NIR) e Infravermelho de Ondas Curtas (SWIR)).
- **Formato:** **GeoTIFF** (Tag Image File Format com informações geoespaciais).
- **Tamanho do Conjunto de Dados:** Várias cenas Sentinel-2 cobrindo a área de estudo (ex: Parque Nacional da Quiçama), com milhares de *patches* rotulados de **128x128 pixels**.

### Pré-processamento e Limpeza de Dados

As imagens de satélite são processadas para garantir consistência:

1. **Correção Atmosférica/Geométrica:** Uso de produtos *Level-2A* (Processado por Sensores/APIs como Google Earth Engine) para remover efeitos atmosféricos e garantir alinhamento geográfico (lidando com *outliers* de ruído atmosférico).
2. **Normalização de Valor de Pixel:** Os valores de pixel brutos (Reflectância TOA/BOA) são tipicamente escalonados de 0 a 10000.0. **Normalização** é feita dividindo-se o pixel por **10000.0**, garantindo que as *features* de entrada para a U-Net estejam dentro do intervalo [0, 1].
3. **Rotulagem (Ground Truth):** Criação das Máscaras de Segmentação (*Ground Truth*) usando ferramentas GIS (como QGIS) para rotular as 5 classes: **Floresta, Savana, Água, Degradação/Solo Exposto e Infraestrutura**.
4. **Patching:** A imagem GeoTIFF completa é dividida em *patches* de **128x128 pixels** para se adequar à memória da GPU e aos requisitos de entrada do modelo U-Net.

---

## 3. Preparando sua Revisão de Tecnologia

### Introdução

A escolha da pilha tecnológica visa a eficiência no processamento de dados geoespaciais e o poder computacional necessário para o Deep Learning.

## Principais Tecnologias e Ferramentas

Categoria	Tecnologia/Ferramenta	Relevância para o Projeto
Linguagem/Ambiente	Python	Padrão em ML e SR. Flexível, com vastas bibliotecas.
Framework DL	TensorFlow 2.x / Keras	Plataforma robusta para construir, treinar e serializar a U-Net.
Modelo Principal	U-Net	Arquitetura de Deep Learning específica para Segmentação Semântica.
Processamento Geoespacial	Rasterio / GDAL	Essencial para ler, manipular e escrever GeoTIFFs (bandas multiespectrais).
Computação Científica	NumPy / Scikit-learn	Para manipulação eficiente de arrays (patches) e cálculo de métricas (IoU).
Plataforma de Treino	Google Colab (GPU/TPU) / Cloud Compute	Oferece a aceleração de hardware necessária para o treino da U-Net.

## Relevância, Comparação e Avaliação

- **Relevância da U-Net:** A arquitetura U-Net é ideal porque suas **Skip Connections** combinam *features* de alta resolução (que preservam bordas) das camadas de *encoder* com *features* de baixo nível (que fornecem contexto) das camadas de *decoder*. Isso é vital para a precisão da segmentação de degradação em limites irregulares.

- **Comparação (DL vs. ML):** Enquanto Random Forest (ML) é rápido, ele classifica pixels individualmente, ignorando relações espaciais. A **U-Net (DL)** usa convolutions para considerar a vizinhança do pixel, resultando em mapas de degradação coerentes e geometricamente mais precisos.
- **Sustentabilidade:** A escolha de tecnologias de código aberto (Python, TensorFlow, Rasterio) garante que a solução seja de baixo custo e facilmente transferível para parceiros locais em Angola (ODS 17).

## Conclusão da Revisão de Tecnologia

A pilha tecnológica proposta, centrada no **Deep Learning (U-Net) com TensorFlow/Keras** e suportada por ferramentas geoespaciais (Rasterio), representa o estado da arte para a segmentação de imagens de satélite. Esta combinação é a mais adequada para entregar uma solução de monitoramento de degradação de alta precisão e escalável, cumprindo os objetivos do projeto.

---

## Referências:

- Belgiu, M., & Drăguț, L. (2016). *Random forest in remote sensing: A review of applications and future directions*. ISPRS Journal of Photogrammetry and Remote Sensing, 114, 24-31.
- Canty, M. J. (2019). *Image analysis, classification and change detection in remote sensing* (3rd ed.). CRC Press.
- Lu, D., Mausel, P., Brondízio, E., & Moran, E. (2004). *Change detection techniques*. International Journal of Remote Sensing, 25(12).
- Ma, L. et al. (2029). *Deep Learning in Remote Sensing Applications: A Meta-Analysis and Review*. ISPRS Journal of Photogrammetry and Remote Sensing, 152, 166-177.
- Zhu, X. X. et al. (2017). *Deep Learning in Remote Sensing: A Comprehensive Review and List of Resources*. IEEE Geoscience and Remote Sensing Magazine, 5(4), 8-36.